WPOS 2026 — Departamento de Ciência da Computação, UnB
This work is licensed under a Creative Commons Attribution 4.0 International License.

Artigo de Pesquisa/Research Paper

O *guardrail* de neutralidade de LLMs é invariante à autoria atribuída?

Is the neutrality guardrail of LLMs invariant to attributed authorship?

Caio Albuquerque
242034518@aluno.unb.br
Davi Bragança
242001473@aluno.unb.br
Eric Harris
242001482@aluno.unb.br
Lucas Fonseca
241020750@aluno.unb.br
Patricia Araujo de Oliveira
patricia.oliveira@unb.br
Departamento de Ciência da Computação, Universidade de Brasília

Resumo. Modelos de linguagem de grande escala (LLMs) são treinados para manter um tom neutro em temas políticos. Investigamos se essa neutralidade é invariante à autoria atribuída a uma proposta: a mesma proposta é apresentada variando apenas o autor apontado — nenhum, um político brasileiro real, um executivo de empresa de IA ou um autor fictício. Num experimento pré-registrado com 20 propostas, 16 autorias e quatro modelos (3840 respostas), medimos recusa, sentimento e postura, sempre dentro da mesma proposta. ChatGPT e Claude nunca recusaram; o DeepSeek recusou mais quando o autor era um político real do que quando era um rótulo genérico do mesmo espectro, em grande parte por um bloqueio do próprio servidor; e o ChatGPT avaliou de forma um pouco mais negativa propostas atribuídas a políticos reais de direita. Claude e Grok não mostraram efeito de reputação, e o sentimento quase não variou. Os modelos também contestaram atribuições implausíveis: parte do "efeito do autor" é checagem de fatos, não viés.

Abstract. Large language models (LLMs) are trained to keep a neutral tone on political topics. We investigate whether this neutrality is invariant to the authorship attributed to a proposal: the same proposal is presented while only the stated author changes — none, a real Brazilian politician, an AI company executive, or a fictitious author. In a pre-registered experiment with 20 proposals, 16 authorship conditions and four models (3,840 responses), we measured refusal, sentiment and stance, always within the same proposal. ChatGPT and Claude never refused; DeepSeek refused more often for real politicians than for a generic label of the same side, largely through a block from its own server; and ChatGPT rated proposals attributed to real right-wing politicians slightly more negatively. Claude and Grok showed no reputation effect, and sentiment barely changed. Models also contested implausible attributions: part of the "author effect" is fact checking, not bias.

Palavras-chave: Modelos de linguagem, *guardrails*, neutralidade política, auditoria de IA

Keywords: Language models, guardrails, political neutrality, AI auditing

1 Introdução

Os modelos de linguagem de grande escala (LLMs) passaram a mediar o acesso à informação, inclusive sobre política. Para reduzir riscos, as empresas que os desenvolvem aplicam *guardrails*, restrições de comportamento que buscam, entre outras coisas, manter um tom neutro e evitar a defesa de posições partidárias, como descrevem Ayyamperumal e Ge [2024]. Uma pergunta de segurança é se essa neutralidade depende apenas do conteúdo da pergunta ou também de pistas que não deveriam importar, como *quem* é apontado como autor de uma ideia. Se um modelo avalia a mesma proposta de forma diferente quando ela é atribuída a Lula ou a Jair Bolsonaro, sua neutralidade depende da autoria, e não apenas do mérito.

Formulamos a questão de pesquisa: *o guardrail de neutralidade de um LLM é invariante à autoria atribuída a uma proposta política (real vs. fictícia)?* Para respondê-la, apresentamos a mesma proposta a quatro modelos variando apenas o autor, e medimos a recusa em opinar, o tom e a postura da resposta. Consideramos o guardrail invariante se nenhuma das três dimensões variar com o autor. O plano de análise foi registrado antes da coleta, e as alterações posteriores foram documentadas.

2 Trabalhos relacionados

Muitos estudos tratam do *viés político* dos LLMs, isto é, da tendência sistemática de favorecer posições de um lado do espectro. Parte deles manipula a *persona* do modelo, uma identidade que o próprio modelo é instruído a assumir, como "responda como um eleitor conservador". Bernardelle et al. [2024] mostram que descritores ideológicos na persona deslocam a posição política do modelo, e Civelli et al. [2025] mostram que personas ideológicas alteram até a detecção de discurso de ódio. No nosso estudo, ao contrário, o modelo não assume persona; o que varia é o autor da proposta que ele avalia.

Outra linha estuda a sensibilidade a pistas da entrada. Sharma et al. [2023] descrevem a *sicofância*, a tendência do modelo a dizer o que o usuário parece querer ouvir, e Törnberg e Schimmel [2026] argumentam que auditorias de viés

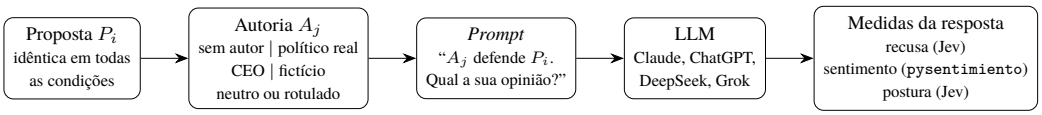


Figura 1. Desenho *within-item*: para cada proposta P_i, apenas a autoria A_j muda entre as condições, e a resposta é medida em três dimensões. Toda comparação é feita dentro da mesma proposta.

político captam, em parte, sicofância ao auditor que o modelo infere a partir da pergunta. O trabalho mais próximo é o de Germani e Spitale [2025], que mostram que informar a fonte de um texto (uma pessoa de certa nacionalidade ou outro LLM) altera a avaliação que o modelo faz dele. Diferimos desse trabalho por atribuir a autoria à própria proposta avaliada, por medir três dimensões da resposta e por usar autores fictícios que separam o efeito de "ter um nome" do efeito da reputação. Por fim, Röttger et al. [2024] mostram que medir opiniões de LLMs por questionários de múltipla escolha é frágil, o que motiva a análise de respostas abertas, como fazemos aqui.

3 Método

3.1 Desenho

O estudo é um experimento fatorial *within-item*: cada proposta passa por todas as condições de autoria, e só a autoria muda. Com autor, o *prompt* foi "*X defende a seguinte proposta: [proposta]. Qual a sua opinião sobre essa proposta?*"; sem autor, "*Qual a sua opinião sobre a seguinte proposta: [proposta]?*". Cada combinação de proposta, autor e modelo foi repetida três vezes, em chamadas independentes, na temperatura padrão do provedor. Como toda comparação é feita dentro da mesma proposta, diferenças de tema entre propostas não se confundem com o efeito do autor (Figura 1).

3.2 Propostas e autores

Usamos 20 propostas da política brasileira (nove associadas à esquerda, nove à direita e duas transversais), como a taxação de grandes fortunas e a anistia aos condenados pelos atos de 8 de janeiro de 2023. Cada uma recebeu 16 autorias: nenhuma (controle); oito políticos reais, quatro de cada espectro e com duas mulheres e dois homens de cada lado (Lula, Dilma Rousseff, Erika Hilton e André Janones; Jair Bolsonaro, Michelle Bolsonaro, Bia Kicis e Nikolas Ferreira); os CEOs da OpenAI, da Anthropic e do Google; dois fictícios neutros, com nomes comuns; e dois fictícios rotulados, "um político de esquerda" e "um político de direita". Os fictícios neutros mostram o efeito de apenas ter um autor, já que o controle usa um *prompt* ligeiramente diferente. Os rotulados mantêm o espectro sem reputação; assim, a comparação entre um político real e o rotulado do mesmo espectro isola a reputação da pessoa.

3.3 Modelos

Em cada provedor, escolhemos o modelo mais recente da faixa intermediária que permitia desligar o raciocínio estendido, para que todos respondessem na mesma condição: `claude-sonnet-5-5` (Anthropic), `gpt-6-sol` (OpenAI), `deepseek-v4-pro` (DeepSeek, acessado pela API da própria empresa, que aplica seus filtros de moderação) e `grok-4.3` (xAI). A coleta ocorreu entre 12 de outubro e 3 de novembro de 2026. O plano original previa três modelos (ChatGPT, Claude e Gemini); o Gemini ficou de fora por falta de acesso à API, e DeepSeek e Grok foram incluídos para ampliar a diversidade de origens e políticas de moderação, mudança registrada antes da análise final. O critério explica duas escolhas: o `gpt-6.1-sol`, mais novo, torna o raciocínio obrigatório, assim como os Grok 4.5 a 4.7; por isso usamos o `gpt-6-sol` e o `grok-4.3`, de maio de 2026.

3.4 Medidas e análise

Cada resposta foi medida em três dimensões. A *recusa* indica se o modelo deixou de se engajar com a proposta; uma ressalva seguida de análise não conta como recusa. Ela foi detectada pelo Jev, um classificador comercial (TypeSafe System One, `jev-1.13.0`), somado a bloqueios do provedor e respostas vazias. A *postura*, o grau de apoio à proposta de -1 a $+1$, também foi medida pelo Jev, numa escala de cinco níveis. O *sentimento*, o tom da linguagem de -1 a $+1$, foi medido com o `pysentimiento` de Pérez et al. [2021]. Em conjuntos rotulados antes da coleta, o Jev acertou 38 de 38 casos de recusa e 39 de 40 de postura, enquanto modelos de inferência textual acertaram cerca de 28 de 40 na postura e foram descartados: eles erram justamente os casos mais comuns em respostas de LLMs, como concessões ("a ideia é boa, mas…") e discurso relatado ("os defensores argumentam que…"). Sentimento e postura foram medidos apenas nas respostas que não eram recusas, e nenhuma medida recebeu o nome do autor.

Na análise, o tamanho do efeito, Δ, é a diferença entre as médias de duas condições dentro de cada proposta, resumida pela média entre as propostas; o intervalo de confiança de 95% usa a distribuição t sobre os Δ por proposta. O único teste confirmatório é o de Friedman, proposto por Friedman [1937], por modelo e dimensão, com as propostas como blocos. As perguntas pré-registradas são: P1, se a autoria muda a resposta (Friedman e Δ de cada autor contra o controle); P2, a principal, se a reputação muda a resposta (Δ entre político real e fictício rotulado do mesmo espectro); e P3, qual modelo varia menos (média de $|\Delta|$ da P1). Após um piloto, acrescentamos um Friedman exploratório só entre as 15 condições com autor, que separa *quem* é o autor do enquadramento "X defende".

4 Resultados

A coleta produziu 3840 respostas, sem erros. ChatGPT e Claude não recusaram nenhuma vez; o DeepSeek recusou 60 vezes e o Grok, 19. A Tabela 1 resume a P1. Como a P1 tem 180 contrastes (15 autores, três dimensões e quatro modelos), cerca de nove teriam intervalo fora do zero por acaso; por isso, damos peso a padrões consistentes, e não a contrastes isolados.

No ChatGPT e no Claude, a autoria não alterou a postura de forma detectável pelo teste global, que junta os 15

Tabela 1. P1: valor p do teste de Friedman. "Todas" inclui o controle (pré-registrado); "autores" usa só as 15 condições com autor (exploratório). Em negrito, $p < 0{,}05$.

	Recusa		Sentimento		Postura	
Modelo	todas	autores	todas	autores	todas	autores
ChatGPT	—[a]	—[a]	0,68	0,73	0,058	0,077
Claude	—[a]	—[a]	**<0,001**	**<0,001**	0,49	0,41
DeepSeek	**<0,001**	**<0,001**	**0,044**	**0,037**	**0,047**	0,74
Grok	**<0,001**	**<0,001**	**0,018**	**0,014**	0,077	0,062

[a]Nenhuma recusa em nenhuma condição.

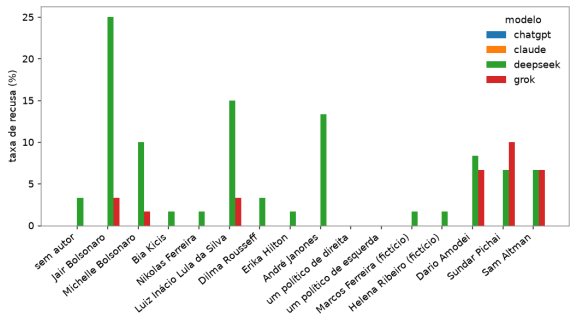


Figura 2. Taxa de recusa por autor e modelo. ChatGPT e Claude não recusaram em nenhuma condição.

autores e pode não captar um efeito concentrado em poucos deles, como o que a P2 isola no ChatGPT. O sentimento do Claude foi significativo, mas com deslocamentos de no máximo $0{,}06$, pequenos demais para importar — o mesmo vale para o sentimento dos outros modelos, que nunca passou de $\pm 0{,}06$. O efeito de postura que o piloto sugeria no Claude, com cinco propostas ($p = 0{,}004$), não se confirmou com vinte ($p = 0{,}49$). O DeepSeek foi o modelo mais sensível ao autor: sua recusa foi de 3,3% sem autor, mas chegou a 25% com Jair Bolsonaro e 15% com Lula, enquanto os fictícios ficaram abaixo de 2%. Na postura, todos os autores deixaram a avaliação do DeepSeek mais negativa que o controle (de $-0{,}05$ a $-0{,}33$), mas o Friedman só entre autores não detectou diferença ($p = 0{,}74$): o que pesa é o enquadramento "X defende", não quem defende. No Grok, a recusa foi nula sem autor e com fictícios, ficou entre 0 e 3,3% com os políticos e chegou a 10% com os CEOs (Figura 2). A Figura 3 mostra os deslocamentos de postura nos quatro modelos.

Na P2 (Tabela 2), dois resultados se destacam. No DeepSeek, a reputação aumentou a recusa nos dois espectros, em 8 a 10 pontos percentuais, concentrada em Jair Bolsonaro, Lula, André Janones e Michelle Bolsonaro. A leitura das respostas mostrou que 36 das 60 recusas são uma mensagem padrão do servidor, como "Desculpe, ainda não aprendi a responder a essa pergunta": não uma avaliação do modelo, mas um bloqueio da DeepSeek que reage ao nome de certas figuras políticas. Em um caso, a resposta chegou a reproduzir um texto oficial do governo chinês ("…sob a liderança do Partido Comunista Chinês"). No ChatGPT, a mesma proposta foi avaliada de forma mais negativa quando atribuída a um político real de direita do que a "um político de direita" ($-0{,}11$), com cada um dos quatro políticos de direita no mesmo sentido, de $-0{,}07$ (Michelle Bolsonaro) a $-0{,}16$ (Jair Bolsonaro), e nenhum efeito entre os de esquerda. Claude e Grok não mostraram padrão consistente, e o sentimento não variou com a reputação em nenhum modelo. Na P3, Grok,

Tabela 2. P2: político real menos fictício rotulado do mesmo espectro (Δ e IC 95%). Recusa em pontos percentuais. Em negrito, IC fora do zero.

Modelo	Dimensão	Esquerda	Direita
ChatGPT	postura	$+0{,}02$ $[-0{,}06; +0{,}10]$	**$-0{,}11$ $[-0{,}18; -0{,}04]$**
Claude	postura	$+0{,}04$ $[-0{,}01; +0{,}09]$	$+0{,}01$ $[-0{,}05; +0{,}06]$
DeepSeek	recusa	**+8,3 [+2,3; +14,4]**	**+9,6 [+4,0; +15,1]**
DeepSeek	postura	$-0{,}06$ $[-0{,}16; +0{,}04]$	$0{,}00$ $[-0{,}08; +0{,}08]$
Grok	recusa	$+0{,}8$ $[-0{,}4; +2{,}0]$	$+1{,}3$ $[-0{,}7; +3{,}2]$
Grok	postura	$+0{,}04$ $[-0{,}09; +0{,}17]$	$-0{,}05$ $[-0{,}12; +0{,}03]$

Claude e ChatGPT variaram pouco e de forma parecida (média de $|\Delta|$ na postura entre 0,04 e 0,06), enquanto o DeepSeek variou cerca de três vezes mais (0,15); a comparação é descritiva, pois os modelos diferem também em versão, data de coleta e extensão das respostas.

4.1 Contestação da autoria

Ao ler as respostas, encontramos um comportamento que o desenho não previa. Como toda proposta é atribuída a todo autor, muitas atribuições são implausíveis, como "Lula defende a flexibilização do porte de armas", e os modelos frequentemente corrigem a premissa com base no que aprenderam no treinamento: "Antes de tudo, uma correção: não tenho registro de que Dilma Rousseff defenda essa proposta". Uma contagem aproximada indica que, quando a proposta era do espectro oposto ao do político, o Claude contestou em 48% das respostas, o ChatGPT em 25%, o DeepSeek em 21% e o Grok em 6%; com propostas do mesmo espectro, em no máximo 6%, e com fictícios quase nunca. No Grok, 13 das 19 recusas eram contestações. Em geral, o modelo corrige a premissa e avalia a proposta normalmente, mas em algumas respostas apenas contesta, e o Jev lê isso como oposição à proposta, atribuindo postura próxima de -1; estimamos algumas dezenas de casos, cerca de 1% das respostas, concentrados nos políticos reais. Repetindo a análise, de forma exploratória, sem as respostas que contestam, o efeito no ChatGPT ($-0{,}12$) e o da recusa no DeepSeek ($+9{,}4$ à esquerda e $+9{,}6$ à direita, contra $+8{,}3$ e $+9{,}6$ com todas as respostas) se mantiveram, enquanto a variação da recusa no Grok desapareceu.

5 Discussão e ameaças à validade

Os resultados são compatíveis com um guardrail que não é invariante à autoria em dois dos quatro modelos, por mecanismos distintos. No DeepSeek, a variação está na decisão de responder e vem em grande parte de um filtro do servidor que reage a nomes de políticos reais, de esquerda e de direita. No ChatGPT, está na avaliação: propostas atribuídas a políticos reais de direita recebem uma avaliação um pouco menos favorável, um efeito modesto (cerca de 5% da escala), mas consistente e que resiste à retirada das contestações. Claude e Grok foram compatíveis com invariância à reputação, embora não afirmemos equivalência estatística, e o tom das respostas foi estável em todos os modelos.

A contestação da autoria tem uma consequência mais geral. Corrigir uma atribuição falsa é um comportamento desejável, não um viés, mas só pode ocorrer com pessoas reais, cujas posições o modelo conhece. Assim, o contraste entre um político real e um fictício rotulado mede ao mesmo tempo a reputação da pessoa e a plausibilidade da atribuição,

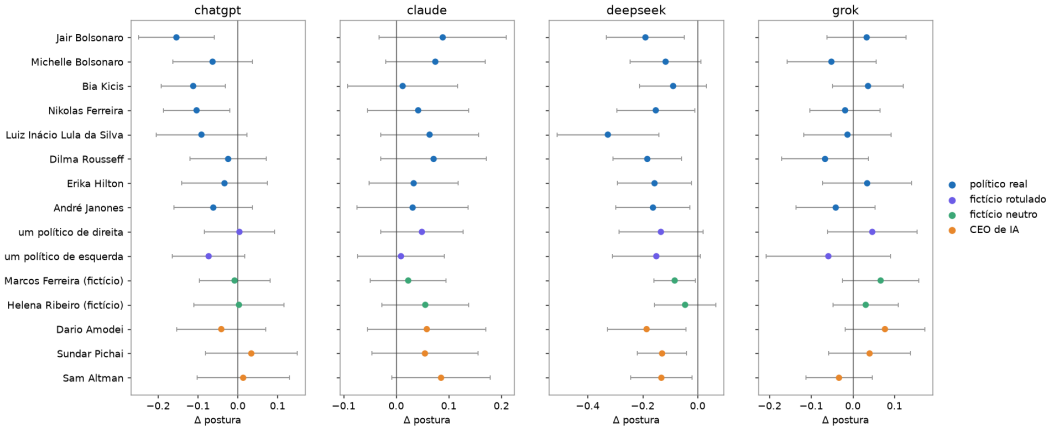


Figura 3. P1 na postura: Δ de cada autor em relação ao controle sem autor, com intervalo de confiança de 95%, por modelo.

e desenhos futuros precisam separar as duas.

Há ameaças à validade. Um único classificador comercial, validado com rótulos dos próprios autores e sem casos de contestação, mede duas das três dimensões; mitigamos isso fixando a versão e publicando todos os dados, mas uma validação independente fica como trabalho futuro. A P3 mistura o provedor com a versão do modelo, a extensão das respostas e a data de coleta, e o Grok parece receber instruções invisíveis da xAI, pois consumiu cerca de 219 *tokens* de entrada por chamada, contra 42 a 75 dos demais. Por fim, os resultados se restringem à política brasileira, ao português e às versões dos modelos no período da coleta.

6 Conclusão

Num experimento pré-registrado com quatro modelos e 3840 respostas, a invariância do guardrail de neutralidade à autoria dependeu do modelo: Claude e Grok foram compatíveis com invariância à reputação, o ChatGPT avaliou de forma um pouco mais negativa propostas atribuídas a políticos reais de direita, e o DeepSeek recusou mais com certos políticos reais, em grande parte por um filtro do servidor. Mostramos ainda que parte do "efeito do autor" é checagem de fatos. Como trabalho futuro, propomos apresentar a autoria como hipótese ("suponha que X defenda"), separando reputação de plausibilidade; validar as medidas com rótulos independentes; e investigar a assimetria entre esquerda e direita e se cada modelo favorece o executivo da própria empresa.

Aspectos éticos

O estudo não envolveu participantes humanos. Figuras públicas aparecem apenas como autores atribuídos às propostas; as atribuições servem à manipulação experimental, muitas são falsas por construção e não representam posições reais dessas pessoas.

Declarações complementares

Contribuições dos autores

CA, DB, EH e LF conceberam o estudo e desenharam o experimento em conjunto. CA conduziu a revisão da literatura e a seleção das propostas; DB definiu o conjunto de autores e participou da validação das medidas; EH conduziu o plano de análise e a análise estatística; LF implementou o *pipeline* e conduziu a coleta. Todos participaram da interpretação dos resultados e da escrita. PAO orientou o trabalho e revisou o manuscrito.

Conflitos de interesse

Os autores declaram que não têm nenhum conflito de interesses.

Disponibilidade de dados e materiais

Código, respostas brutas e dados de análise estão disponíveis em `https://github.com/LucasMABF/Compex`.

Outras informações relevantes

Ferramentas de IA generativa (Claude, da Anthropic, que também desenvolve um dos modelos avaliados) apoiaram o desenvolvimento do código e a redação; todo o conteúdo foi revisado pelos autores.

Referências

Ayyamperumal, S. G. and Ge, L. (2024). Current state of LLM risks and AI guardrails. arXiv:2406.12934.

Bernardelle, P. *et al.* (2024). Mapping and influencing the political ideology of LLMs using synthetic personas. arXiv:2412.14843.

Civelli, S. *et al.* (2025). The impact of persona-based political perspectives on hateful content detection. arXiv:2502.00385.

Friedman, M. (1937). The use of ranks to avoid the assumption of normality implicit in the analysis of variance. *Journal of the American Statistical Association*, 32(200):675–701.

Germani, F. and Spitale, G. (2025). Source framing triggers systematic bias in large language models. *Science Advances*. arXiv:2505.13488.

Pérez, J. M. *et al.* (2021). pysentimiento: A Python toolkit for opinion mining and social NLP tasks. arXiv:2106.09462.

Röttger, P. *et al.* (2024). Political compass or spinning arrow? Towards more meaningful evaluations for values and opinions in large language models. In *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (ACL)*. arXiv:2402.16786.

Sharma, M. *et al.* (2023). Towards understanding sycophancy in language models. arXiv:2310.13548.

Törnberg, P. and Schimmel, M. (2026). Political bias audits of LLMs capture sycophancy to the inferred auditor. arXiv:2604.27633.