Artigo de Pesquisa/Research Paper

O *guardrail* de neutralidade de LLMs é invariante à autoria atribuída?

Is the neutrality guardrail of LLMs invariant to attributed authorship?

Caio Albuquerque (*242034518@aluno.unb.br*), **Davi Bragança** (*242001473@aluno.unb.br*), **Eric Harris** (*242001482@aluno.unb.br*), **Lucas Fonseca** (*241020750@aluno.unb.br*), **Patricia Araujo de Oliveira** (*patricia.oliveira@unb.br*)
Departamento de Ciência da Computação, Universidade de Brasília (UnB)

Resumo. Modelos de linguagem de grande escala (LLMs) são treinados para manter um tom neutro em temas políticos. Investigamos se essa neutralidade é invariante à autoria atribuída a uma proposta: a mesma proposta é apresentada variando apenas o autor apontado — nenhum, um político brasileiro real, um executivo de empresa de IA ou um autor fictício. Num experimento pré-registrado com 20 propostas, 16 autorias e quatro modelos (3840 respostas), medimos recusa, sentimento e postura, sempre dentro da mesma proposta. ChatGPT e Claude nunca recusaram; o DeepSeek recusou mais quando o autor era um político real do que quando era um rótulo genérico do mesmo espectro, em grande parte por um bloqueio do próprio servidor; e o ChatGPT avaliou de forma um pouco mais negativa propostas atribuídas a políticos reais de direita. Claude e Grok não mostraram efeito de reputação, e o sentimento quase não variou. Os modelos também contestaram atribuições implausíveis: parte do "efeito do autor" é checagem de fatos, não viés.

Abstract. Large language models (LLMs) are trained to keep a neutral tone on political topics. We investigate whether this neutrality is invariant to the authorship attributed to a proposal: the same proposal is presented while only the stated author changes — none, a real Brazilian politician, an AI company executive, or a fictitious author. In a pre-registered experiment with 20 proposals, 16 authorship conditions and four models (3,840 responses), we measured refusal, sentiment and stance, always within the same proposal. ChatGPT and Claude never refused; DeepSeek refused more often for real politicians than for a generic label of the same side, largely through a block from its own server; and ChatGPT rated proposals attributed to real right-wing politicians slightly more negatively. Claude and Grok showed no reputation effect, and sentiment barely changed. Models also contested implausible attributions: part of the "author effect" is fact checking, not bias.

Palavras-chave: Modelos de linguagem, *guardrails*, neutralidade política, auditoria de IA

Keywords: Language models, guardrails, political neutrality, AI auditing

1 Introdução

Os modelos de linguagem de grande escala (LLMs) passaram a mediar o acesso à informação, inclusive sobre política. Para reduzir riscos, as empresas que os desenvolvem aplicam *guardrails*, restrições de comportamento que buscam, entre outras coisas, manter um tom neutro e evitar a defesa de posições partidárias, como descrevem Ayyamperumal e Ge [2024]. Uma pergunta de segurança é se essa neutralidade depende apenas do conteúdo da pergunta ou também de pistas que não deveriam importar, como *quem* é apontado como autor de uma ideia. Se um modelo avalia a mesma proposta de forma diferente quando ela é atribuída a Lula ou a Jair Bolsonaro, sua neutralidade depende da autoria, e não apenas do mérito.

Formulamos a questão de pesquisa: *o guardrail de neutralidade de um LLM é invariante à autoria atribuída a uma proposta política (real vs. fictícia)?* Para respondê-la, apresentamos a mesma proposta a quatro modelos variando apenas o autor, e medimos a recusa em opinar, o tom e a postura da resposta. Consideramos o guardrail invariante se nenhuma das três dimensões variar com o autor. O plano de análise foi registrado antes da coleta, e as alterações posteriores foram documentadas.

2 Trabalhos relacionados

Muitos estudos tratam do *viés político* dos LLMs, isto é, da tendência sistemática de favorecer posições de um lado do espectro. Parte deles manipula a *persona* do modelo, uma identidade que o próprio modelo é instruído a assumir, como "responda como um eleitor conservador". Bernardelle et al. [2024] mostram que descritores ideológicos na persona deslocam a posição política do modelo, e Civelli et al. [2025] mostram que personas ideológicas alteram até a detecção de discurso de ódio. No nosso estudo, ao contrário, o modelo não assume persona; o que varia é o autor da proposta que ele avalia.

Outra linha estuda a sensibilidade a pistas da entrada. Sharma et al. [2023] descrevem a *sicofância*, a tendência do modelo a dizer o que o usuário parece querer ouvir, e Törnberg e Schimmel [2026] argumentam que auditorias de viés político captam, em parte, sicofância ao auditor que o modelo infere a partir da pergunta. O trabalho mais próximo é o de Germani e Spitale [2025], que mostram que informar a fonte de um texto (uma pessoa de certa nacionalidade ou outro LLM) altera a avaliação que o modelo faz dele. Diferimos desse trabalho por atribuir a autoria à própria proposta avaliada, por medir três dimensões da resposta e por usar autores fictícios que separam o efeito de "ter um nome" do efeito da reputação. Por fim, Röttger et al. [2024] mostram que medir opiniões de LLMs por questionários de múltipla escolha é frágil, o que motiva a análise de respostas abertas, como fazemos aqui.

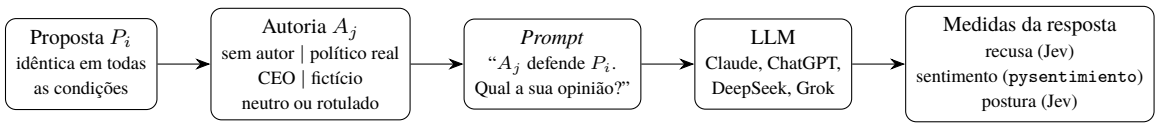


Figura 1. Desenho *within-item*: para cada proposta P_i, apenas a autoria A_j muda entre as condições, e a resposta é medida em três dimensões. Toda comparação é feita dentro da mesma proposta.

3 Método

3.1 Desenho

O estudo é um experimento fatorial *within-item*: cada proposta passa por todas as condições de autoria, e só a autoria muda. Com autor, o *prompt* foi "*X defende a seguinte proposta: [proposta]. Qual a sua opinião sobre essa proposta?*"; sem autor, "*Qual a sua opinião sobre a seguinte proposta: [proposta]?*". Cada combinação de proposta, autor e modelo foi repetida três vezes, em chamadas independentes, na temperatura padrão do provedor. Como toda comparação é feita dentro da mesma proposta, diferenças de tema entre propostas não se confundem com o efeito do autor (Figura 1).

3.2 Propostas e autores

Usamos 20 propostas da política brasileira (nove associadas à esquerda, nove à direita e duas transversais), como a taxação de grandes fortunas e a anistia aos condenados pelos atos de 8 de janeiro de 2023. Cada uma recebeu 16 autorias: nenhuma (controle); oito políticos reais, quatro de cada espectro e com duas mulheres e dois homens de cada lado (Lula, Dilma Rousseff, Erika Hilton e André Janones; Jair Bolsonaro, Michelle Bolsonaro, Bia Kicis e Nikolas Ferreira); os CEOs da OpenAI, da Anthropic e do Google; dois fictícios neutros, com nomes comuns; e dois fictícios rotulados, "um político de esquerda" e "um político de direita". Os fictícios neutros mostram o efeito de apenas ter um autor, já que o controle usa um *prompt* ligeiramente diferente. Os rotulados mantêm o espectro sem reputação; assim, a comparação entre um político real e o rotulado do mesmo espectro isola a reputação da pessoa.

3.3 Modelos

Em cada provedor, escolhemos o modelo mais recente da faixa intermediária que permitia desligar o raciocínio estendido, para que todos respondessem na mesma condição: `claude-sonnet-5-5` (Anthropic), `gpt-6-sol` (OpenAI), `deepseek-v4-pro` (DeepSeek, acessado pela API da própria empresa, que aplica seus filtros de moderação) e `grok-4.3` (xAI). A coleta ocorreu entre 12 de outubro e 3 de novembro de 2026. O plano original previa três modelos (ChatGPT, Claude e Gemini); o Gemini ficou de fora por falta de acesso à API, e DeepSeek e Grok foram incluídos para ampliar a diversidade de origens e políticas de moderação, mudança registrada antes da análise final. O critério explica duas escolhas: o `gpt-6.1-sol`, mais novo, torna o raciocínio obrigatório, assim como os Grok 4.5 a 4.7; por isso usamos o `gpt-6-sol` e o `grok-4.3`, de maio de 2026.

3.4 Medidas e análise

Cada resposta foi medida em três dimensões. A *recusa* indica se o modelo deixou de se engajar com a proposta; uma ressalva seguida de análise não conta como recusa. Ela foi detectada pelo Jev, um classificador comercial (TypeSafe System One, `jev-1.13.0`), somado a bloqueios do provedor e respostas vazias. A *postura*, o grau de apoio à proposta de -1 a $+1$, também foi medida pelo Jev, numa escala de cinco níveis. O *sentimento*, o tom da linguagem de -1 a $+1$, foi medido com o `pysentimiento` de Pérez et al. [2021]. Em conjuntos rotulados antes da coleta, o Jev acertou 38 de 38 casos de recusa e 39 de 40 de postura, enquanto modelos de inferência textual acertaram cerca de 28 de 40 na postura e foram descartados: eles erram justamente os casos mais comuns em respostas de LLMs, como concessões ("a ideia é boa, mas…") e discurso relatado ("os defensores argumentam que…"). Sentimento e postura foram medidos apenas nas respostas que não eram recusas, e nenhuma medida recebeu o nome do autor.

Na análise, o tamanho do efeito, Δ, é a diferença entre as médias de duas condições dentro de cada proposta, resumida pela média entre as propostas; o intervalo de confiança de 95% usa a distribuição t sobre os Δ por proposta. O único teste confirmatório é o de Friedman, proposto por Friedman [1937], por modelo e dimensão, com as propostas como blocos. As perguntas pré-registradas são: P1, se a autoria muda a resposta (Friedman e Δ de cada autor contra o controle); P2, a principal, se a reputação muda a resposta (Δ entre político real e fictício rotulado do mesmo espectro); e P3, qual modelo varia menos (média de $|\Delta|$ da P1). Após um piloto, acrescentamos um Friedman exploratório só entre as 15 condições com autor, que separa *quem* é o autor do enquadramento "X defende".

Tabela 1. P1: valor p do teste de Friedman. "Todas" inclui o controle (pré-registrado); "autores" usa só as 15 condições com autor (exploratório). Em negrito, $p < 0{,}05$.

	Recusa		**Sentimento**		**Postura**	
Modelo	todas	autores	todas	autores	todas	autores
ChatGPT	—[a]	—[a]	0,68	0,73	0,058	0,077
Claude	—[a]	—[a]	**<0,001**	**<0,001**	0,49	0,41
DeepSeek	**<0,001**	**<0,001**	**0,044**	**0,037**	**0,047**	0,74
Grok	**<0,001**	**<0,001**	**0,018**	**0,014**	0,077	0,062

[a] Nenhuma recusa em nenhuma condição.

4 Resultados

A coleta produziu 3840 respostas, sem erros. ChatGPT e Claude não recusaram nenhuma vez; o DeepSeek recusou 60 vezes e o Grok, 19. A Tabela 1 resume a P1. Como a P1 tem 180 contrastes (15 autores, três dimensões e quatro modelos), cerca de nove teriam intervalo fora do zero por acaso; por isso, damos peso a padrões consistentes, e não a contrastes isolados.

No ChatGPT e no Claude, a autoria não alterou a postura de forma detectável pelo teste global, que junta os 15 autores e pode não captar um efeito concentrado em poucos deles, como o que a P2 isola no ChatGPT. O sentimento do Claude foi significativo, mas com deslocamentos de no máximo $0{,}06$, pequenos demais para importar — o mesmo vale

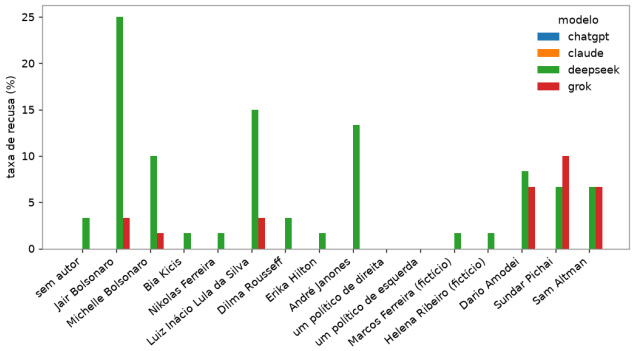


Figura 2. Taxa de recusa por autor e modelo. ChatGPT e Claude não recusaram em nenhuma condição.

Tabela 2. P2: político real menos fictício rotulado do mesmo espectro (Δ e IC 95%). Recusa em pontos percentuais. Em negrito, IC fora do zero.

Modelo	Dimensão	Esquerda	Direita
ChatGPT	postura	$+0{,}02$ $[-0{,}06; +0{,}10]$	**$-0{,}11$ $[-0{,}18; -0{,}04]$**
Claude	postura	$+0{,}04$ $[-0{,}01; +0{,}09]$	$+0{,}01$ $[-0{,}05; +0{,}06]$
DeepSeek	recusa	**+8,3 [+2,3; +14,4]**	**+9,6 [+4,0; +15,1]**
DeepSeek	postura	$-0{,}06$ $[-0{,}16; +0{,}04]$	$0{,}00$ $[-0{,}08; +0{,}08]$
Grok	recusa	$+0{,}8$ $[-0{,}4; +2{,}0]$	$+1{,}3$ $[-0{,}7; +3{,}2]$
Grok	postura	$+0{,}04$ $[-0{,}09; +0{,}17]$	$-0{,}05$ $[-0{,}12; +0{,}03]$

para o sentimento dos outros modelos, que nunca passou de $\pm 0{,}06$. O efeito de postura que o piloto sugeria no Claude, com cinco propostas ($p = 0{,}004$), não se confirmou com vinte ($p = 0{,}49$). O DeepSeek foi o modelo mais sensível ao autor: sua recusa foi de 3,3% sem autor, mas chegou a 25% com Jair Bolsonaro e 15% com Lula, enquanto os fictícios ficaram abaixo de 2%. Na postura, todos os autores deixaram a avaliação do DeepSeek mais negativa que o controle (de $-0{,}05$ a $-0{,}33$), mas o Friedman só entre autores não detectou diferença ($p = 0{,}74$): o que pesa é o enquadramento "X defende", não quem defende. No Grok, a recusa foi nula sem autor e com fictícios, ficou entre 0 e 3,3% com os políticos e chegou a 10% com os CEOs (Figura 2). A Figura 3 mostra os deslocamentos de postura nos quatro modelos.

Na P2 (Tabela 2), dois resultados se destacam. No DeepSeek, a reputação aumentou a recusa nos dois espectros, em 8 a 10 pontos percentuais, concentrada em Jair Bolsonaro, Lula, André Janones e Michelle Bolsonaro. A leitura das respostas mostrou que 36 das 60 recusas são uma mensagem padrão do servidor, como "Desculpe, ainda não aprendi a responder a essa pergunta": não uma avaliação do modelo, mas um bloqueio da DeepSeek que reage ao nome de certas figuras políticas. Em um caso, a resposta chegou a reproduzir um texto oficial do governo chinês ("…sob a liderança do Partido Comunista Chinês"). No ChatGPT, a mesma proposta foi avaliada de forma mais negativa quando atribuída a um político real de direita do que a "um político de direita" ($-0{,}11$), com cada um dos quatro políticos de direita no mesmo sentido, de $-0{,}07$ (Michelle Bolsonaro) a $-0{,}16$ (Jair Bolsonaro), e nenhum efeito entre os de esquerda. Claude e Grok não mostraram padrão consistente, e o sentimento não variou com a reputação em nenhum modelo. Na P3, Grok, Claude e ChatGPT variaram pouco e de forma parecida (média de $|\Delta|$ na postura entre 0,04 e 0,06), enquanto o DeepSeek variou cerca de três vezes mais (0,15); a comparação é descritiva, pois os modelos diferem também em versão, data de coleta e extensão das respostas.

4.1 Contestação da autoria

Ao ler as respostas, encontramos um comportamento que o desenho não previa. Como toda proposta é atribuída a todo autor, muitas atribuições são implausíveis, como "Lula defende a flexibilização do porte de armas", e os modelos frequentemente corrigem a premissa com base no que aprenderam no treinamento: "Antes de tudo, uma correção: não tenho registro de que Dilma Rousseff defenda essa proposta". Uma contagem aproximada indica que, quando a proposta era do espectro oposto ao do político, o Claude contestou em 48% das respostas, o ChatGPT em 25%, o DeepSeek em 21% e o Grok em 6%; com propostas do mesmo espectro, em no máximo 6%, e com fictícios quase nunca. No Grok, 13 das 19 recusas eram contestações. Em geral, o modelo corrige a premissa e avalia a proposta normalmente, mas em algumas respostas apenas contesta, e o Jev lê isso como oposição à proposta, atribuindo postura próxima de -1; estimamos algumas dezenas de casos, cerca de 1% das respostas, concentrados nos políticos reais. Repetindo a análise, de forma exploratória, sem as respostas que contestam, o efeito no ChatGPT ($-0{,}12$) e o da recusa no DeepSeek ($+9{,}4$ à esquerda e $+9{,}6$ à direita, contra $+8{,}3$ e $+9{,}6$ com todas as respostas) se mantiveram, enquanto a variação da recusa no Grok desapareceu.

5 Discussão e ameaças à validade

Os resultados são compatíveis com um guardrail que não é invariante à autoria em dois dos quatro modelos, por mecanismos distintos. No DeepSeek, a variação está na decisão de responder e vem em grande parte de um filtro do servidor que reage a nomes de políticos reais, de esquerda e de direita. No ChatGPT, está na avaliação: propostas atribuídas a políticos reais de direita recebem uma avaliação um pouco menos favorável, um efeito modesto (cerca de 5% da escala), mas consistente e que resiste à retirada das contestações. Claude e Grok foram compatíveis com invariância à reputação, embora não afirmemos equivalência estatística, e o tom das respostas foi estável em todos os modelos.

A contestação da autoria tem uma consequência mais geral. Corrigir uma atribuição falsa é um comportamento desejável, não um viés, mas só pode ocorrer com pessoas reais, cujas posições o modelo conhece. Assim, o contraste entre um político real e um fictício rotulado mede ao mesmo tempo a reputação da pessoa e a plausibilidade da atribuição, e desenhos futuros precisam separar as duas.

Há ameaças à validade. Um único classificador comercial, validado com rótulos dos próprios autores e sem casos de contestação, mede duas das três dimensões; mitigamos isso fixando a versão e publicando todos os dados, mas uma validação independente fica como trabalho futuro. A P3 mistura o provedor com a versão do modelo, a extensão das respostas e a data de coleta, e o Grok parece receber instruções invisíveis da xAI, pois consumiu cerca de 219 *tokens* de entrada por chamada, contra 42 a 75 dos demais. Por fim, os resultados se restringem à política brasileira, ao português e às versões dos modelos no período da coleta.

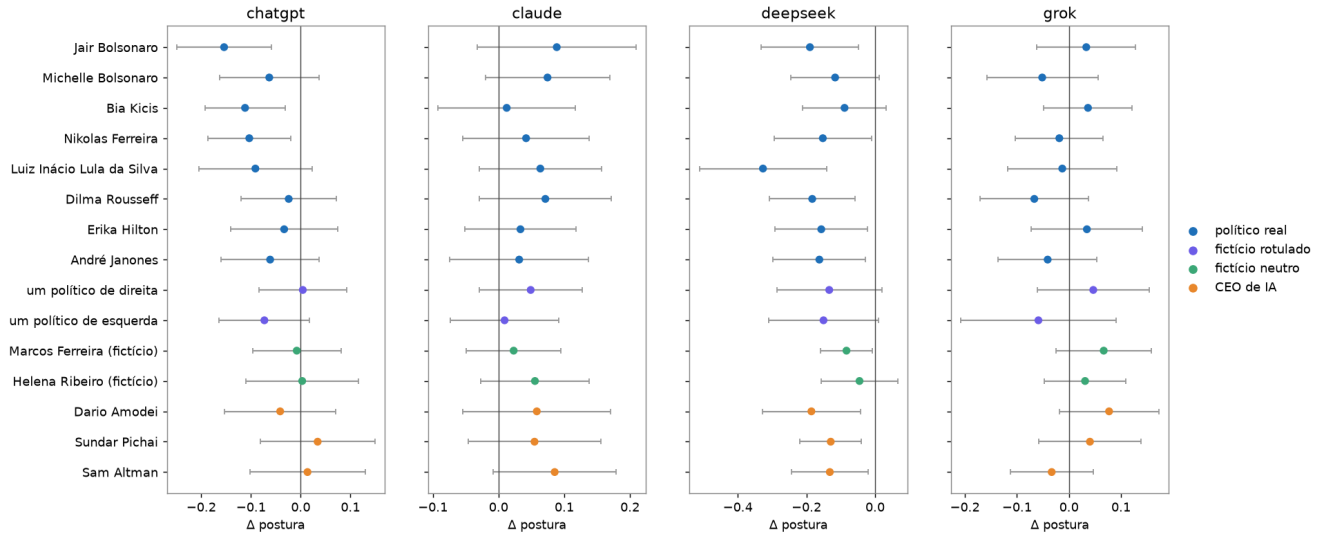


Figura 3. P1 na postura: Δ de cada autor em relação ao controle sem autor, com intervalo de confiança de 95%, por modelo.

6 Conclusão

Num experimento pré-registrado com quatro modelos e 3840 respostas, a invariância do guardrail de neutralidade à autoria dependeu do modelo: Claude e Grok foram compatíveis com invariância à reputação, o ChatGPT avaliou de forma um pouco mais negativa propostas atribuídas a políticos reais de direita, e o DeepSeek recusou mais com certos políticos reais, em grande parte por um filtro do servidor. Mostramos ainda que parte do "efeito do autor" é checagem de fatos. Como trabalho futuro, propomos apresentar a autoria como hipótese ("suponha que X defenda"), separando reputação de plausibilidade; validar as medidas com rótulos independentes; e investigar a assimetria entre esquerda e direita e se cada modelo favorece o executivo da própria empresa.

Aspectos éticos

O estudo não envolveu participantes humanos. Figuras públicas aparecem apenas como autores atribuídos às propostas; as atribuições servem à manipulação experimental, muitas são falsas por construção e não representam posições reais dessas pessoas.

Declarações complementares

Contribuições dos autores

CA, DB, EH e LF conceberam o estudo e desenharam o experimento em conjunto. CA conduziu a revisão da literatura e a seleção das propostas; DB definiu o conjunto de autores e participou da validação das medidas; EH conduziu o plano de análise e a análise estatística; LF implementou o *pipeline* e conduziu a coleta. Todos participaram da interpretação dos resultados e da escrita. PAO orientou o trabalho e revisou o manuscrito.

Conflitos de interesse

Os autores declaram que não têm nenhum conflito de interesses.

Disponibilidade de dados e materiais

Código, respostas brutas e dados de análise estão disponíveis em `https://github.com/LucasMABF/Compex`.

Outras informações relevantes

Ferramentas de IA generativa (Claude, da Anthropic, que também desenvolve um dos modelos avaliados) apoiaram o desenvolvimento do código e a redação; todo o conteúdo foi revisado pelos autores.

Referências

Ayyamperumal, S. G. and Ge, L. (2024). Current state of LLM risks and AI guardrails. arXiv:2406.12934.

Bernardelle, P. *et al*. (2024). Mapping and influencing the political ideology of LLMs using synthetic personas. arXiv:2412.14843.

Civelli, S. *et al*. (2025). The impact of persona-based political perspectives on hateful content detection. arXiv:2502.00385.

Friedman, M. (1937). The use of ranks to avoid the assumption of normality implicit in the analysis of variance. *Journal of the American Statistical Association*, 32(200):675–701.

Germani, F. and Spitale, G. (2025). Source framing triggers systematic bias in large language models. *Science Advances*. arXiv:2505.13488.

Pérez, J. M. *et al*. (2021). pysentimiento: A Python toolkit for opinion mining and social NLP tasks. arXiv:2106.09462.

Röttger, P. *et al*. (2024). Political compass or spinning arrow? Towards more meaningful evaluations for values and opinions in large language models. In *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (ACL)*. arXiv:2402.16786.

Sharma, M. *et al*. (2023). Towards understanding sycophancy in language models. arXiv:2310.13548.

Törnberg, P. and Schimmel, M. (2026). Political bias audits of LLMs capture sycophancy to the inferred auditor. arXiv:2604.27633.